

TAM THUC STRATEGEM

RAG Service - Full Implementation Detail v1.0

1. MỤC TIÊU CỦA RAG SERVICE

RAG (Retrieval-Augmented Generation) Service có nhiệm vụ:

- Lấy thông tin liên quan từ Knowledge Base (patterns + classical excerpts)
- Kết hợp với chart data và user query
- Gửi đến LLM để tạo interpretation chất lượng cao, có nguồn gốc rõ ràng

2. KIẾN TRÚC CHÍNH

1. **Embedding Service**

- Dùng model embedding (OpenAI text-embedding-3-small hoặc local model)
- Embed toàn bộ knowledge chunks (patterns + classical text)

2. **Vector Database**

- Lưu embeddings + metadata (Chroma, Pinecone, hoặc Weaviate)

3. **Retriever**

- Khi có query + chart data → embed query → tìm top-k relevant chunks

4. **Prompt Constructor**

- Kết hợp: System prompt + Retrieved context + Chart data + User query + Persona level

5. **LLM Caller**

- Gọi LLM (GPT-4o, Claude 3.5, hoặc local model)
- Parse output thành structured JSON

3. PROMPT TEMPLATE MẪU

```
python system_prompt = ''' Bạn là chuyên gia Tam Thức có 30 năm kinh nghiệm. Dựa trên chart data và retrieved knowledge, hãy đưa ra interpretation. Luôn phân biệt Beginner mode và Expert mode. Trích dẫn nguồn khi có thể. ''' user_prompt = f''' User Query: {user_query} Chart Data Summary: {chart_summary} Detected Patterns: {patterns} Retrieved Knowledge: {retrieved_chunks} Hãy trả lời theo JSON format sau: {{ "beginner_interpretation": "...", "expert_interpretation": "...", "recommendations": [...], "confidence": 0.XX }}'''
```

4. LƯU Ý QUAN TRỌNG

- Cần chunking knowledge base tốt (mỗi pattern + classical excerpt là một chunk).
- Nên có metadata filtering (lọc theo system: qimen/liuren/taiyi).
- Cần evaluation loop: đo lường chất lượng output (faithfulness, relevance, citation accuracy).
- Có thể kết hợp với Rule Engine output để tăng độ chính xác.